ΕΛΛΗΝΙΚΗ ΔΗΜΟΚΡΑΤΙΑ

ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ

Big Data : Εργασία 1

Γεωργιάνα Πετρίδου ics23143
Θεοδώρα Στάμογλου iis22144

Θέμα 1: Spark RDD API

Πίνακας Εκτέλεσης :

	Action Time
1η επ.	1.9998810291290283
2η επ.	2.5545027256011963
3η επ.	1.465510606765747
4η επ.	2.5066192150115967
5η επ.	1.5745935440063477

Αν εξαιρέσουμε τις Τιμές (min/max): 1.4655 / 2.5545 , ο Μ.Ο. είναι **2.0270 sec**

Θέμα 2: Spark DataFrame API

Πίνακας Εκτέλεσης :

	Action Time
1η επ.	0.39929986000061035
2η επ.	0.3691532611846924
3η επ.	0.585012674331665
4η επ.	0.51700758934021
5η επ.	0.583709716796875

Αν εξαιρέσουμε τις Τιμές (min/max): 0.3692 / 0.5850, ο Μ.Ο. είναι: **0.5000 sec.**

<u>Θέμα 3</u>: Συγκριτική Ανάλυση RDD vs DataFrame

Η ανάλυση αυτή βασίζεται στην σύγκριση της υλοποίησης του **Θέματος 1 (RDD API)** με την υλοποίηση του **Θέματος 2 (DataFrame API).**

Η υλοποίηση με **RDD** είναι πιο απαιτητική ως προς την διαχείριση των δομών δεδομένων. Αυτο γίνεται εύκολα αντιληπτό από το γεγονός ότι, ο υπολογισμός του Μ.Ο. χρειάζεται την χειροκίνητη χρήση του 'combineByKey' για την κατασκευή του αθροίσματος και του πλήθους, κάνοντας τον κώδικα πιο περίπλοκο και επιρρεπή σε λάθη.

Αντίθετα, το **DataFrame** χρησιμοποιεί μια πιο εκφραστική και high level προσέγγιση, καθώς αν ρίξει κανείς μια γρήγορη ματιά, του είναι πιο εύκολο να καταλάβει για τι χρησιμοποιείται αυτός ο κώδικας. Αυτό ενισχύεται και από την ύπαρξη ενεργειών που γίνονται με δηλωτικό τρόπο (πχ. df.groupBy().agg(avg())), κάνοντας τον ευκολότερο στην συντήρηση αλλά και πιο ευανάγνωστο.

Ως προς τους χρόνους εκτέλεσης, ο μ.ο. του **RDD** είναι **2.0270 sec,** ενώ στο **DataFrame** είναι **0.5000 sec.** Αν και αναμενόμενο, ο χρόνος εκτέλεσης του DataFrame είναι σημαντικά μικρότερος από αυτόν του RDD κατά σχεδόν ¾. Αυτό συμβαίνει γιατί ο κώδικας του RDD στον Spark εκτελείται ακριβώς όπως έχει γραφτεί από τον χρήστη, χωρίς να μπορεί να μπορεί να αναλύσει ή να βελτιστοποιήσει τις λειτουργίες του.

Πίνακας Εκτέλεσης :

RDD	Action Time		DataFrame	Action Time
1η επ.	1.9998810291290283		1η επ.	1.9998810291290283
2η επ.	2.5545027256011963		2η επ.	2.5545027256011963
3η επ.	1.465510606765747		3η επ.	1.465510606765747
4η επ.	2.5066192150115967		4η επ.	2.5066192150115967
5η επ.	1.5745935440063477		5η επ.	1.5745935440063477

RDD: Αν εξαιρέσουμε τις Τιμές (min/max): 1.4655 / 2.5545 , ο Μ.Ο. είναι **2.0270 sec**
DataFrame: Αν εξαιρέσουμε τις Τιμές (min/max): 0.3692 / 0.5850, ο Μ.Ο. είναι: **0.5000 sec.**

Ο συνολικός χρόνος εκτέλεσης του RDD (αρχή - αποτέλεσμα) = 12.3 sec και του DataFrame = 3.1 sec

Αξίζει να αναφερθεί ότι DataFrames στο Spark έχουν δυνατότητες βελτιστοποίησης (Catalyst optimizer), καθώς λειτουργούν με δομημένα δεδομένα και μεταδεδομένα (schema). Αυτό σημαίνει ότι παρέχει στο Spark την πλήρη εικόνα και μπορεί να αναλύει, σχεδιάζει και βελτιστοποιεί αυτόματα το φυσικό πλάνο εκτέλεσης. Αυτό παίζει επίσης σημαντικό ρόλο και στην διαφορα του χρόνου εκτέλεσης, αφού το RDD δεν έχει αυτές τις δυνατότητες και αντιμετωπίζεται σαν "black box".

Συμπερασματικά, με βάση τα κριτήρια και κυρίως, την δυνατότητα βελτιστοποίησης, η προσέγγιση DataFrames θεωρείται καταλληλότερη για μεγάλα σύνολα δεδομένων και εφαρμογές παραγωγής. Ο λόγος είναι ότι ο catalyst optimizer διασφαλίζει ότι, ανεξάρτητα από την πολυπλοκότητα του query, το Spark θα βρει τον πιο αποδοτικό τρόπο εκτέλεσης. Έτσι, έχουμε αποτελεσματική κλιμάκωση της εφαρμογής σε clusters με χιλιαδες κόμβους, κάτι που δεν μπορεί να επιτευχθεί με την ίδια ευκολία μέσω του RDD. Παρ'όλα αυτά, τα RDDs παραμένουν απαραίτητα για πολύπλοκες, μη δομημένες λειτουργίες χαμηλού επιπέδου.

Θέμα 4: Οπτικοποίηση & Ανάλυση

Το οριζόντιο ραβδόγραμμα δείχνει τις 10 αεροπορικές διαδρομές (Routes) με τις υψηλότερες μέσες καθυστερήσεις αναχώρησης. Από την ανάλυση προκύπτουν τα εξής συμπεράσματα:

- **Κορυφαία Διαδρομή:** Η διαδρομή **DFW-JFK** (Dallas προς Νέα Υόρκη) καταγράφει τη μεγαλύτερη μέση καθυστέρηση (**23.3 λεπτά**), γεγονός που την καθιστά την πιο επιβαρυμένη διαδρομή στο συγκεκριμένο σύνολο δεδομένων.
- **Επιβάρυνση Κόμβων (Hubs):** Παρατηρείται έντονη παρουσία διαδρομών που συνδέουν ή καταλήγουν σε μεγάλα αεροδρόμια-κόμβους, όπως το JFK (Νέα Υόρκη), ή το MIA (Μαϊάμι) . Αυτό υποδεικνύει ότι η κυκλοφοριακή συμφόρηση σε αυτά τα αεροδρόμια επηρεάζει σημαντικά την ακρίβεια των αναχωρήσεων, για αυτό και πρέπει δοθεί η ανάλογη προσοχή.
- **Διαδρομές Μεγάλων Αποστάσεων:** Στις κορυφαίες θέσεις εμφανίζονται και διαδρομές μεγάλων αποστάσεων, όπως JFK-LAS και DFW-JFK, όπου οι καθυστερήσεις είναι συχνά πιο δύσκολο να ανακτηθούν κατά τη διάρκεια της πτήσης.

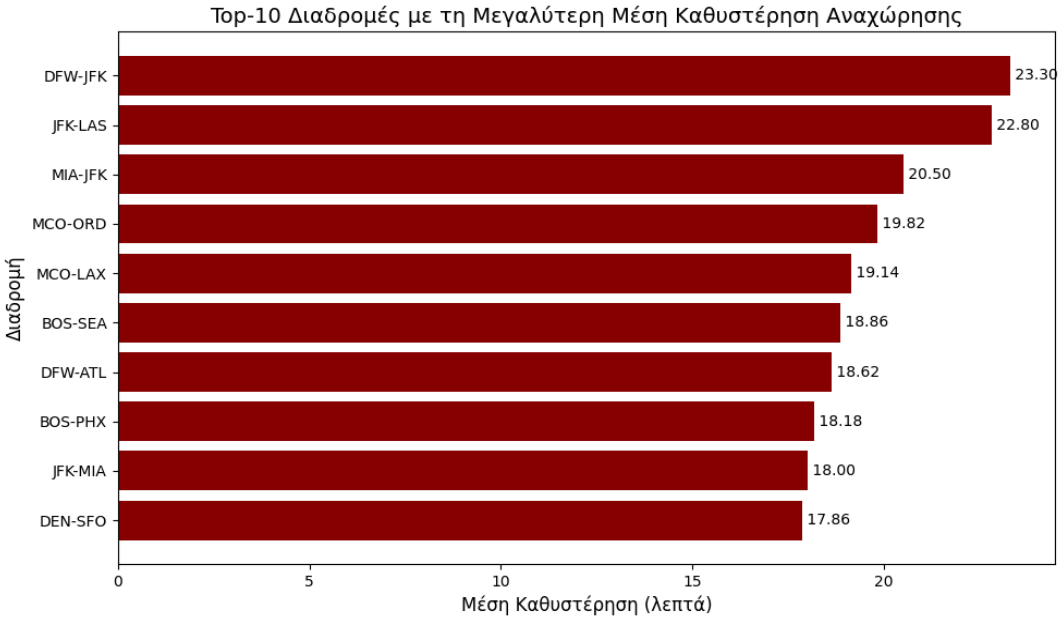

Θέμα 5: Επέκταση / Εμπλουτισμός Ανάλυσης

Σκοπός και Ανάδειξη

Ο λόγος που επεκτείναμε την ανάλυση, ήταν για να αναδείξουμε τις αιτίες καθυστερήσεων των πτήσεων που ίσως να μην είναι προφανείς. Χρησιμοποιώντας κι άλλου είδους οπτικοποιήσεις για την μέση καθυστέρηση ανα ώρα αναχώρησης αλλά και την κατανομή των καθυστερήσεων αυτών ανά αεροπορική εταιρεια και ανά διαδρομή, προσπαθήσαμε να δούμε αν υπάρχουν κρυμμένα μοτίβα και παράγοντες που τις δημιουργούν.

1. Μέση Καθυστέρηση Αναχώρησης ανά ώρα

Η ανάλυση αυτή διερευνά την διακύμανση των καθυστερήσεων κατά τη διάρκεια του 24ώρου, προκειμένου να εντοπιστούν χρονικά μοτίβα συμφόρησης και ώρες αιχμής. Παρατηρείται ότι οι πτήσεις νωρίς το πρωί έχουν ελάχιστες καθυστερήσεις, ενώ τις απογευματινές και βραδινές ώρες αυξάνεται, καθώς τα προβλήματα προηγούμενων πτήσεων μεταφέρονται στις επόμενες.

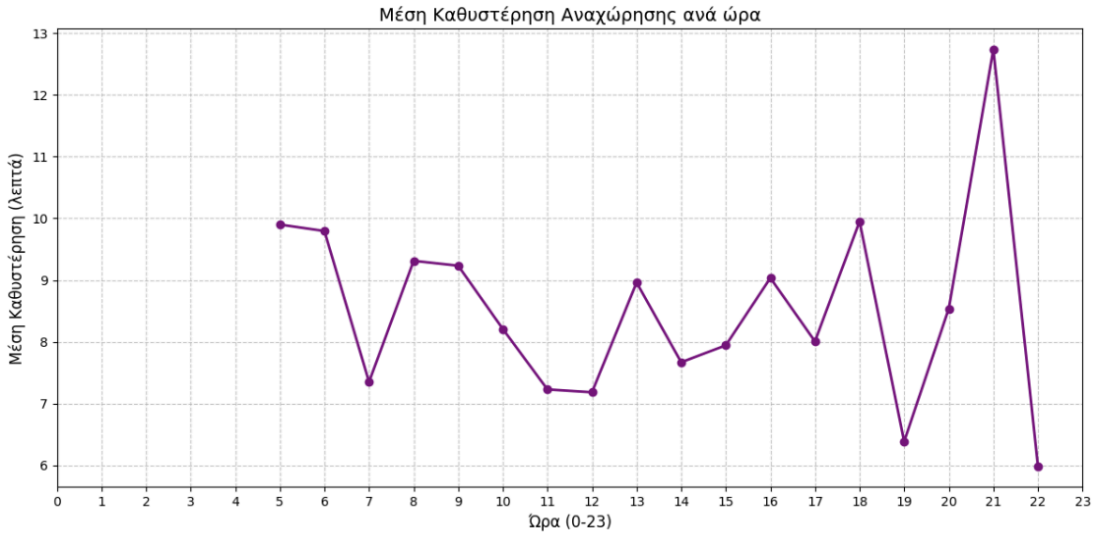

2. Μέση Καθυστέρηση Αναχώρησης ανά Αεροπορική Εταιρεία

Σκοπός είναι να αξιολογηθεί η επιχειρησιακή απόδοση των αεροπορικών εταιρειών, ώστε να διαπιστωθεί ποιες είναι πιο συνεπείς στα προγράμματα τους. Το γράφημα απεικονίζει σημαντικές αποκλίσεις στην αξιοπιστία μεταξύ των εταιρειών. Ορισμένες αεροπορικές καταφέρνουν να διατηρούν πολύ χαμηλούς μέσους όρους καθυστέρησης, ενώ άλλες αντιμετωπίζουν συστηματικά προβλήματα, γεγονός που μπορεί να οφείλεται στη διαχείριση του στόλου τους ή στα αεροδρόμια που χρησιμοποιούν.

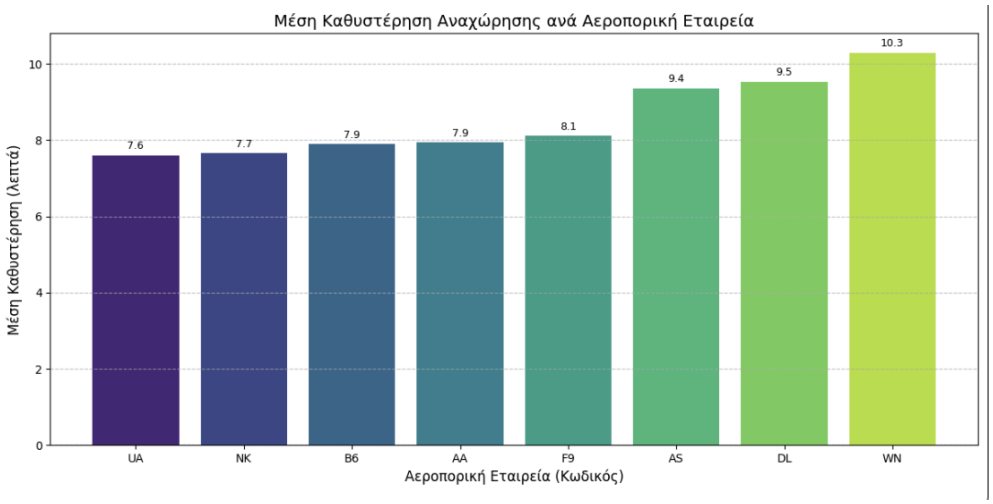

3. Καθυστερήσεις ανά Διαδρομή (Top-15 Αεροδρόμια)

Η οπτικοποίηση μέσω του Heatmap στοχεύει, στον γεωγραφικο εντοπισμό των προβλημάτων του δικτύου, εξετάζοντας τη μέση καθυστέρηση για συγκεκριμένα ζεύγη αεροδρομίων. Αυτό αναδεικνύει συγκεκριμένες διαδρομές που έχουν υψηλές καθυστερήσεις (έντονο κόκκινο) και άλλες με λιγότερες ή καθόλου (ψυχρά χρώματα - μπλε). Έτσι, φανερόνονται τα πιθανά προβλήματα στον σχεδιασμό των πτήσεων ή συμφόρησης μεταξύ των δύο πόλεων (Αναχώρησης -Προορισμού).

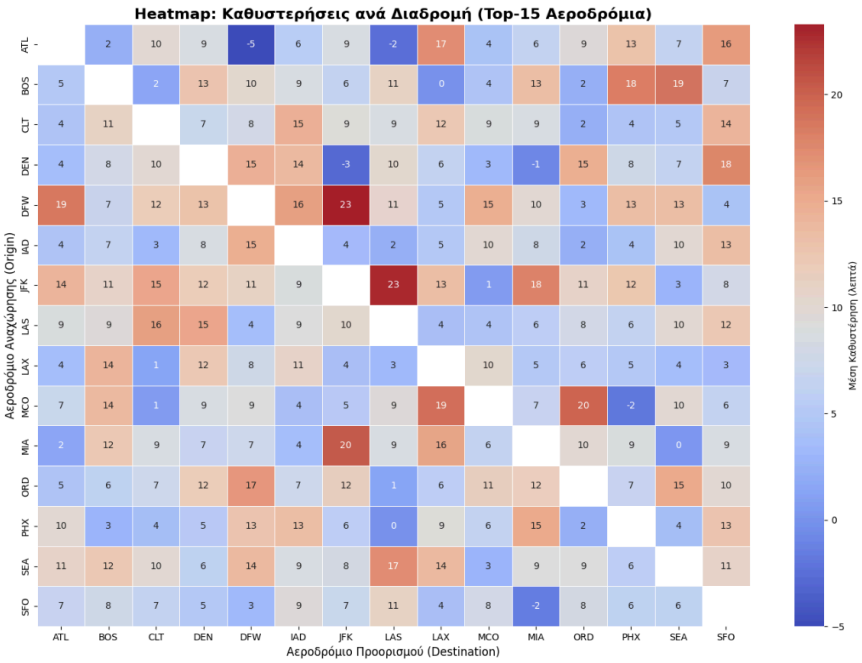

Περιβάλλον Εκτέλεσης - Θεοδώρα Σταμογλου, iis22144

Laptop - Lenovo ideapad c340 -140API (AMD -Ryzen 5, 8 RAM)

Περιβάλλον Εκτέλεσης - Γεωργιάνα Πετρίδου, ics23143

Laptop - Macbook Pro 13 (M1)

Χρήση Gemini για απορίες, επεξήγηση και διόρθωση συντακτικών λαθών των κειμένων.